

Cahier des charges PFA

Sujet proposé

Restauration et extraction fiable d'informations dans des documents scannés bruités : approche OCR + Layout + validation sémantique

Proposé pour : Projet de Fin d'Année — Master 1

Nature du projet : Projet de recherche appliquée en Text Mining, Document AI et extraction d'information

Encadrant : Hafidi Imad - Achraf Msadek

****Email :** i.hafidi@usms.ma - achrafmsadek7@gmail.com

Durée estimée : 2 mois

Technologies principales : Python, OpenCV, OCR, PyTorch, Transformers, LayoutLM/LayoutLMv3, outils d'évaluation NLP/OCR

Introduction

La numérisation massive des documents administratifs, bancaires, médicaux et commerciaux a rendu indispensable le développement de systèmes capables d'extraire automatiquement des informations à partir de documents scannés. Cependant, dans les contextes réels, les documents sont rarement propres : ils peuvent être mal scannés, inclinés, flous, bruités, partiellement coupés, faiblement contrastés ou contenir une mise en page complexe.

Les systèmes classiques d'OCR permettent de convertir une image de document en texte, mais ils restent sensibles à la qualité visuelle du document. Une erreur d'OCR peut ensuite se propager vers les étapes suivantes : extraction d'entités, association question-réponse, indexation, recherche documentaire ou alimentation d'une base de données. Ainsi, la problématique ne se limite pas à reconnaître du texte, mais consiste à produire une information structurée, fiable et accompagnée d'un niveau de confiance.

Ce projet propose de concevoir et d'évaluer un pipeline complet pour l'extraction fiable d'informations à partir de documents scannés bruités. Le pipeline visé suit la chaîne suivante :

prétraitement image → OCR → analyse de layout → extraction d'entités ou de paires clé-valeur → validation sémantique → score de confiance

Le projet s'appuiera principalement sur le dataset FUNSD, conçu pour la compréhension de formulaires scannés bruités. Le travail consistera à comparer plusieurs stratégies d'extraction, à générer des versions artificiellement dégradées des documents, puis à analyser l'impact des dégradations sur la qualité des résultats.

Problématique de recherche

Les systèmes actuels d'extraction d'information documentaire donnent souvent de bons résultats sur des documents propres ou bien structurés. En revanche, leurs performances diminuent fortement lorsque les documents sont bruités, inclinés, flous ou présentent une mise en page complexe. Dans un contexte réel, cette fragilité pose un problème majeur, car les erreurs d'extraction peuvent entraîner des décisions incorrectes, une mauvaise indexation, une perte d'information ou une saisie erronée dans les systèmes d'information.

La question centrale de ce projet est donc :

Comment construire un pipeline capable d'extraire des informations fiables à partir de documents scannés bruités ou dégradés, tout en évaluant la qualité et la confiance associées aux informations extraites ?

Cette problématique peut être déclinée en plusieurs sous-questions :

1. Quel est l'impact des dégradations visuelles sur la qualité de l'OCR ?
 2. Le prétraitement d'image améliore-t-il réellement l'extraction d'information ?
 3. L'exploitation de la mise en page du document améliore-t-elle la reconnaissance des entités ?
 4. Comment associer une information extraite à un score de confiance exploitable ?
 5. Comment analyser les erreurs produites par les différentes approches ?
-

Objectifs du projet

Objectif principal

Concevoir, implémenter et évaluer un pipeline Python permettant l'extraction fiable d'informations à partir de documents scannés bruités, en combinant OCR, analyse de layout, extraction d'entités et validation sémantique.

Objectifs secondaires

Le projet vise à atteindre les objectifs suivants :

1. Étudier les fondements de l'OCR, de l'analyse de layout et de l'extraction d'information dans les documents scannés.
 2. Explorer le dataset FUNSD et comprendre sa structure : images, mots, boîtes englobantes, entités sémantiques et relations.
 3. Mettre en place une première chaîne OCR de base sur les documents.
 4. Appliquer différentes techniques de prétraitement d'image : correction d'inclinaison, débruitage, binarisation, amélioration du contraste et redimensionnement.
 5. Générer des versions artificiellement dégradées des documents pour simuler des cas réels.
 6. Comparer les performances d'un OCR brut avec celles d'un OCR après prétraitement.
 7. Étudier l'apport des modèles layout-aware pour l'extraction d'entités ou de paires clé-valeur.
 8. Proposer une stratégie simple de validation sémantique par règles ou modèle léger.
 9. Construire un score de confiance par champ extrait.
 10. Produire une analyse comparative des performances, des erreurs et des limites observées.
 11. Préparer un dépôt GitHub reproductible contenant les notebooks, scripts, résultats et documentation.
-

Données et ressources utilisées

Dataset principal : FUNSD

Le dataset principal recommandé est FUNSD, un jeu de données destiné à la compréhension de formulaires scannés bruités. Il contient des documents réels annotés avec des mots, des boîtes englobantes, des entités sémantiques et des

relations.

Dans ce projet, FUNSD sera utilisé pour étudier :

- la reconnaissance de texte ;
- la localisation des mots ;
- l'analyse de layout ;
- l'identification d'entités ;
- l'association entre questions et réponses ;
- l'évaluation de la robustesse des approches face aux dégradations.

Remarque importante sur les champs à extraire

FUNSD est particulièrement adapté à l'extraction de structures de type formulaire, notamment les relations entre questions, réponses, en-têtes et autres éléments. Si le projet vise explicitement des champs comme nom, date, montant, référence ou adresse, deux stratégies sont possibles :

1. utiliser les paires question-réponse disponibles dans FUNSD et sélectionner les champs compatibles ;
2. compléter l'expérimentation par un petit jeu de documents synthétiques ou par un dataset de reçus/factures si les champs montant, date et référence doivent être fortement représentés.

Taxonomie des approches étudiées

Le projet organisera les méthodes étudiées selon la taxonomie suivante :

1. Approches basées OCR brut

Ces approches appliquent directement un moteur OCR sur l'image sans amélioration préalable. Elles servent de baseline pour mesurer les difficultés liées au bruit et à la qualité du scan.

Exemples d'outils possibles :

- Tesseract OCR ;
- EasyOCR ;
- PaddleOCR.

2. Approches OCR avec prétraitement d'image

Ces approches améliorent l'image avant l'OCR afin de réduire les erreurs de reconnaissance.

Techniques possibles :

- conversion en niveaux de gris ;
- binarisation ;
- correction d'inclinaison ;
- suppression du bruit ;
- amélioration du contraste ;
- filtrage morphologique ;
- redimensionnement.

3. Approches layout-aware

Ces méthodes exploitent non seulement le texte reconnu, mais aussi la position spatiale des mots dans le document. Elles sont adaptées aux formulaires, factures, reçus et documents semi-structurés.

Exemples de modèles :

- LayoutLM ;
- LayoutLMv2 ;
- LayoutLMv3 ;
- LayoutXLM pour des perspectives multilingues.

4. Approches OCR-free

Ces méthodes cherchent à comprendre le document directement à partir de l'image, sans dépendre explicitement d'un moteur OCR externe. Elles peuvent être étudiées comme perspective avancée, mais leur implémentation complète peut dépasser le cadre du PFA.

Exemple :

- Donut, Document Understanding Transformer.

5. Validation sémantique et score de confiance

Cette famille d'approches vise à vérifier si l'information extraite est plausible. Elle peut utiliser :

- des règles métier ;
- des expressions régulières ;
- des contraintes de format ;
- des dictionnaires ;
- des scores OCR ;
- des scores de modèle ;
- une combinaison pondérée de plusieurs signaux.

Revue bibliographique indicative

La revue bibliographique du projet devra couvrir les axes suivants :

1. OCR et reconnaissance de texte dans les documents scannés.
2. Prétraitement d'image pour améliorer la qualité des documents.
3. Analyse de layout pour les documents semi-structurés.
4. Extraction d'entités et de paires clé-valeur.
5. Modèles multimodaux pour Document AI.
6. Robustesse des systèmes OCR face aux dégradations.
7. Évaluation de la fiabilité et des scores de confiance.

Références initiales recommandées

1. Jaume, G., Ekenel, H. K., & Thiran, J.-P. FUNSD: A Dataset for Form Understanding in Noisy Scanned Documents.
2. Xu, Y. et al. LayoutLM: Pre-training of Text and Layout for Document Image Understanding.
3. Huang, Y. et al. LayoutLMv3: Pre-training for Document AI with Unified Text and Image Masking.
4. Kim, G. et al. OCR-free Document Understanding Transformer.

5. Huang, Z. et al. ICDAR2019 Competition on Scanned Receipt OCR and Information Extraction.
 6. Travaux récents sur la robustesse des systèmes Visual Document Understanding sous bruit, attaques ou perturbations visuelles.
-

Méthodologie proposée

Le projet sera conduit en six phases complémentaires. Chaque phase combine étude théorique, implémentation pratique, expérimentation et documentation.

Phase 1 : Étude du contexte et prise en main du dataset

Objectifs

- Comprendre la problématique de l'extraction d'information dans les documents bruités.
- Étudier la structure du dataset FUNSD.
- Préparer l'environnement technique de travail.

Travaux à réaliser

- Lire les articles principaux sur FUNSD, OCR et Document AI.
- Télécharger et organiser le dataset.
- Visualiser les documents et leurs annotations.
- Comprendre les formats d'annotation : mots, bounding boxes, labels, relations.
- Préparer un notebook exploratoire.

Résultats attendus

- Une note de synthèse sur le dataset.
 - Des visualisations de documents annotés.
 - Un premier script de lecture et d'affichage des annotations.
 - Une description claire des champs et entités exploitables.
-

Phase 2 : Construction d'un benchmark de dégradation documentaire

Objectifs

Créer des versions artificiellement dégradées des documents afin de tester la robustesse des méthodes.

Dégradations à simuler

- Flou gaussien.
- Bruit aléatoire.
- Rotation légère.
- Faible contraste.
- Compression JPEG.
- Effet scan dégradé.
- Décalage ou légère distorsion.

- Ombres ou zones partiellement assombries.

Travaux à réaliser

- Définir une fonction de dégradation paramétrable.
- Générer plusieurs niveaux de difficulté : faible, moyen, fort.
- Sauvegarder les images dégradées avec leurs paramètres.
- Documenter les transformations appliquées.

Résultats attendus

- Un module Python de génération de documents bruités.
 - Un mini-benchmark contenant les documents originaux et leurs versions dégradées.
 - Une grille de dégradation claire et reproductible.
-

Phase 3 : Baseline OCR brut

Objectifs

Évaluer les performances d'un OCR appliqué directement sur les documents sans prétraitement.

Travaux à réaliser

- Choisir un ou plusieurs moteurs OCR.
- Appliquer l'OCR sur les documents originaux.
- Appliquer l'OCR sur les documents dégradés.
- Comparer le texte reconnu avec les annotations disponibles.
- Calculer des métriques OCR.

Métriques possibles

- CER : Character Error Rate.
- WER : Word Error Rate.
- Taux de mots correctement reconnus.
- Taux de mots non détectés.
- Qualité des bounding boxes si disponible.

Résultats attendus

- Un notebook OCR baseline.
 - Un tableau de résultats OCR sur documents propres et dégradés.
 - Une première analyse des types d'erreurs.
-

Phase 4 : OCR avec prétraitement d'image

Objectifs

Évaluer si le prétraitement améliore la qualité de l'OCR et de l'extraction.

Travaux à réaliser

- Implémenter plusieurs techniques de prétraitement avec OpenCV.
- Appliquer chaque technique avant l'OCR.
- Comparer les performances avec la baseline.
- Identifier les prétraitements les plus utiles selon le type de dégradation.

Prétraitements possibles

- Correction d'inclinaison.
- Binarisation adaptative.
- Débruitage.
- Amélioration de contraste.
- Redimensionnement.
- Filtrage morphologique.

Résultats attendus

- Un pipeline OCR avec prétraitement.
- Une comparaison OCR brut vs OCR avec prétraitement.
- Une analyse par type de dégradation.
- Une recommandation des meilleurs prétraitements selon les cas.

Phase 5 : Extraction d'entités et exploitation du layout

Objectifs

Passer de la reconnaissance de texte à l'extraction d'information structurée.

Travaux à réaliser

- Extraire les entités ou paires clé-valeur à partir des sorties OCR.
- Exploiter les coordonnées spatiales des mots.
- Tester une approche simple par règles.
- Tester une approche layout-aware si le temps et les ressources le permettent.
- Comparer les résultats sur documents propres et dégradés.

Approches possibles

1. Approche règles + OCR

Utilisation de mots-clés, expressions régulières, formats de dates, formats numériques et voisinage spatial.

2. Approche OCR + layout

Utilisation des positions des mots pour associer labels et valeurs.

3. Approche layout-aware

Fine-tuning ou inférence avec un modèle de type LayoutLM ou LayoutLMv3.

Résultats attendus

- Un module d'extraction d'information.
- Une sortie structurée au format JSON ou CSV.
- Une évaluation des entités extraites.
- Une comparaison entre approche textuelle simple et approche exploitant le layout.

Phase 6 : Validation sémantique, score de confiance et analyse d'erreurs

Objectifs

Évaluer la fiabilité des informations extraites et proposer un score de confiance par champ.

Travaux à réaliser

- Définir des règles de validation selon le type d'information.
- Combiner plusieurs signaux de confiance :
 - score OCR ;
 - score du modèle d'extraction ;
 - conformité au format attendu ;
 - cohérence spatiale ;
 - présence d'un label proche ;
 - stabilité sous plusieurs prétraitements.
- Construire un score global de fiabilité.
- Analyser les erreurs restantes.

Exemples de règles

- Une date doit respecter un format temporel valide.
- Un montant doit être numérique et éventuellement accompagné d'une devise.
- Une référence doit respecter une longueur ou un motif particulier.
- Une réponse doit être spatialement proche de sa question.
- Un champ extrait avec faible score OCR doit être marqué comme incertain.

Résultats attendus

- Un score de confiance par champ extrait.
- Une matrice d'erreurs.
- Une analyse qualitative des cas d'échec.
- Des recommandations pour améliorer le système.

Planification sur 8 semaines

Semaine	Travail prévu	Résultat attendu
Semaine 1	Étude bibliographique, installation, prise en main de FUNSD	Note de synthèse + environnement prêt
Semaine 2	Exploration du dataset, visualisation des annotations	Notebook d'exploration
Semaine 3	Génération des documents dégradés	Module de dégradation
Semaine 4	OCR brut sur documents originaux et bruités	Baseline OCR + premiers résultats
Semaine 5	Prétraitement image + OCR amélioré	Comparaison OCR brut/prétraité
Semaine 6	Extraction d'entités ou paires clé-valeur	Sorties structurées JSON/CSV

Semaine 7	Validation sémantique + score de confiance	Matrice d'erreurs + score de fiabilité
Semaine 8	Rapport final, présentation, nettoyage du dépôt GitHub	Rapport + slides + code reproductible

Environnement technique recommandé

Langage

- Python 3.10 ou version supérieure.

Bibliothèques principales

- OpenCV pour le prétraitement d'image.
- NumPy et Pandas pour la manipulation des données.
- Matplotlib ou Plotly pour la visualisation.
- Tesseract OCR, EasyOCR ou PaddleOCR pour la reconnaissance de texte.
- PyTorch pour les modèles deep learning.
- Transformers pour les modèles de type LayoutLM/LayoutLMv3.
- Scikit-learn pour les métriques et l'analyse.
- Jupyter Notebook ou Google Colab pour l'expérimentation.

Organisation du dépôt GitHub

Le dépôt du projet devra contenir au minimum :

```
document-ai-noisy-extraction/
|
├─ data/
|   ├── raw/
|   ├── degraded/
|   └─ processed/
|
├─ notebooks/
|   ├── 01_dataset_exploration.ipynb
|   ├── 02_degradation_generation.ipynb
|   ├── 03_ocr_baseline.ipynb
|   ├── 04_preprocessing_ocr.ipynb
|   ├── 05_information_extraction.ipynb
|   └─ 06_error_analysis_confidence.ipynb
|
├─ src/
|   ├── degradation.py
|   ├── preprocessing.py
|   ├── ocr_engine.py
|   ├── extraction.py
|   ├── validation.py
|   └─ evaluation.py
|
├─ results/
|   ├── figures/
|   ├── tables/
|   └─ error_analysis/
|
├─ README.md
└─ requirements.txt
```

Critères d'évaluation expérimentale

L'évaluation devra porter sur trois niveaux complémentaires.

1. Évaluation OCR

- CER : taux d'erreur caractère.
- WER : taux d'erreur mot.
- Taux de mots détectés.
- Taux de mots manquants.
- Impact des dégradations sur la reconnaissance.

2. Évaluation extraction d'information

- Précision.
- Rappel.
- F1-score.
- Exact match pour les champs extraits.
- Partial match lorsque la valeur est partiellement correcte.
- Taux de champs non extraits.
- Taux de champs incorrectement extraits.

3. Évaluation de robustesse

- Comparaison document original vs document dégradé.
- Perte de performance selon le type de bruit.
- Perte de performance selon le niveau de dégradation.
- Sensibilité aux rotations, au flou et au faible contraste.

4. Évaluation du score de confiance

- Corrélation entre score de confiance et exactitude réelle.
 - Taux d'erreurs détectées comme faibles confiances.
 - Taux de bonnes extractions classées comme fiables.
 - Analyse des faux positifs et faux négatifs de confiance.
-

Livrables attendus

À la fin du projet, l'étudiant devra fournir :

1. Un rapport bibliographique sur l'OCR, le Document AI, l'analyse de layout et l'extraction d'information à partir de documents bruités.
2. Un notebook d'exploration du dataset FUNSD.
3. Un module de génération de documents artificiellement dégradés.
4. Une baseline OCR sur documents originaux et dégradés.
5. Un pipeline OCR avec prétraitement d'image.
6. Un module d'extraction d'entités ou de paires clé-valeur.

7. Une méthode simple de validation sémantique.
 8. Un score de confiance par champ extrait.
 9. Une matrice d'erreurs détaillée.
 10. Une comparaison expérimentale des différentes approches.
 11. Un dépôt GitHub propre, documenté et reproductible.
 12. Une présentation finale.
 13. Une synthèse courte de type article de recherche, pouvant servir de base à un futur sujet de thèse.
-

Valeur scientifique attendue

Ce projet a une valeur scientifique importante car il ne se limite pas à appliquer un OCR existant. Il propose une démarche complète d'analyse de fiabilité dans un contexte réaliste de documents dégradés.

La contribution principale attendue est la construction d'un cadre expérimental permettant de mesurer :

- l'effet des dégradations sur l'OCR ;
- l'intérêt réel du prétraitement d'image ;
- l'apport de la mise en page dans l'extraction d'information ;
- la capacité d'un score de confiance à identifier les extractions risquées ;
- les limites des systèmes actuels face aux documents bruités.

Le projet peut également produire une base expérimentale utile pour des travaux ultérieurs en Document AI, extraction d'information robuste et archivage numérique intelligent.

Valeur applicative attendue

Les résultats de ce projet peuvent être réutilisés dans plusieurs domaines :

- numérisation d'archives administratives ;
 - extraction d'informations à partir de formulaires ;
 - traitement automatique de dossiers bancaires ;
 - lecture automatique de documents d'assurance ;
 - indexation de documents juridiques ;
 - analyse de factures et reçus ;
 - préparation de données pour un système RAG documentaire ;
 - contrôle qualité de documents scannés.
-

Limites prévues

Le projet présente certaines limites qu'il faudra expliciter dans le rapport :

1. Le dataset FUNSD est relativement petit.
2. Les champs disponibles dans FUNSD ne couvrent pas forcément tous les types de données comme montant, date ou adresse.
3. Les performances peuvent dépendre fortement du moteur OCR choisi.
4. Le fine-tuning de modèles layout-aware peut nécessiter des ressources GPU.
5. Les dégradations artificielles ne reproduisent pas parfaitement tous les défauts des vrais documents scannés.

6. Le score de confiance proposé restera une première approximation.

Risques et stratégies de mitigation

Risque	Impact	Stratégie de mitigation
Dataset trop limité	Résultats difficiles à généraliser	Limiter le scope à FUNSD et documenter clairement les limites
OCR peu performant	Extraction dégradée	Tester plusieurs OCR ou se concentrer sur l'analyse comparative
Manque de GPU	Difficulté à fine-tuner LayoutLM	Utiliser des modèles pré-entraînés, réduire le volume ou privilégier les règles/layout
Champs non disponibles	Extraction spécifique difficile	Travailler sur les paires clé-valeur plutôt que sur des champs métier imposés
Temps limité	Pipeline incomplet	Prioriser OCR + prétraitement + extraction + confiance simple
Résultats faibles	Difficulté d'interprétation	Valoriser l'analyse d'erreurs et la robustesse plutôt que la seule performance

Conclusion

Ce projet propose une étude complète et appliquée de l'extraction fiable d'informations à partir de documents scannés bruités. En combinant prétraitement d'image, OCR, analyse de layout, extraction d'entités, validation sémantique et score de confiance, l'étudiant développera une compréhension solide des défis actuels du Document AI.

Le projet est adapté à un PFA de Master 1 car il combine lecture scientifique, expérimentation pratique, analyse comparative et production de livrables reproductibles. Il constitue également une excellente base pour un futur travail de Master 2 ou une thèse portant sur la robustesse, la fiabilité et l'auditabilité des systèmes d'extraction d'information documentaire.

Annexe : matrice comparative suggérée

Approche	Famille	Idée principale	Force	Limite
OCR brut	Baseline OCR	Appliquer directement l'OCR sur l'image	Simple, rapide, facile à comparer	Très sensible au bruit et au flou
OCR + prétraitement	Vision classique	Améliorer l'image avant reconnaissance	Peut améliorer fortement la lecture	Le meilleur prétraitement dépend du type de bruit
OCR + règles	Extraction symbolique	Utiliser regex, mots-clés et formats attendus	Interprétable, peu coûteux	Fragile face à la variabilité des documents
OCR + layout	Extraction spatiale	Exploiter les positions des mots	Utile pour formulaires et paires clé-valeur	Dépend de la qualité des bounding boxes

LayoutLM/LayoutLMv3	Modèle layout-aware	Combiner texte, position et représentation visuelle	Adapté aux documents semi-structurés	Peut nécessiter GPU et préparation complexe
Donut	OCR-free Document AI	Comprendre le document directement depuis l'image	Réduit la dépendance à l'OCR	Plus avancé, parfois lourd pour un PFA
Validation sémantique	Contrôle qualité	Vérifier cohérence et format des champs extraits	Améliore la fiabilité finale	Ne corrige pas toutes les erreurs
Score de confiance	Fiabilité	Attribuer un niveau de confiance à chaque champ	Utile pour audit et décision humaine	Calibration difficile

Ressource pratique attendue

L'étudiant devra préparer son propre dépôt GitHub comme point de départ pratique. Le dépôt devra contenir les scripts, notebooks, fichiers de configuration, résultats expérimentaux, visualisations, documentation d'installation et instructions de reproduction. Si des dépôts externes sont utilisés, ils devront être clairement listés, documentés et adaptés dans l'environnement du projet.